UNIVERSIDAD CENTRAL
Vigilada Mineducación

Informe Sprint 1 (Canciones)

Camila Alejandra Aguado Urrego

Samuel Felipe Bustos Munca

Vanesa Tatiana Caminos Boyaca

Data Analytics

Elias Buitrago Bolivar

Universidad Central

Facultad de Ingeniería y Ciencias Básicas

Bogotá

2026

UNIVERSIDAD CENTRAL
Vigilada Mineducación

Informe de la Semana 9: ¿qué popularidad tendrá una canción antes de lanzarla?

Entrenamos un modelo lineal con canciones de 1995-2019 y lo evaluamos con canciones de 2020-2025. Hallamos que se equivoca en promedio 5.75 puntos de popularidad, frente a 10.44 de la línea base (la media por género), lo que equivale a una reducción del 45 % del error; además, el 84 % de las canciones queda dentro de ±10 puntos. Notamos que dos columnas del archivo (reproducciones de la primera semana y es_hit) hacían que el modelo pareciera casi perfecto

1. Pregunta de negocio

Una disquera decide antes del lanzamiento en qué canciones invertir en promoción. Nos planteamos la siguiente pregunta: ¿qué popularidad (de 0 a 100) alcanzará una canción nueva? Como la decisión se toma antes de lanzar, usamos solo variables que ya existen en ese momento.

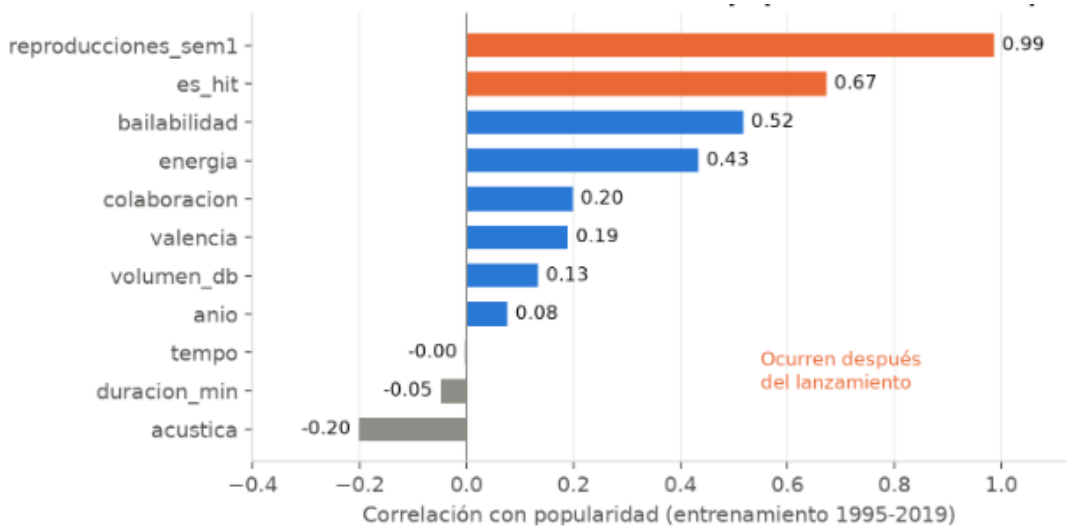
- Datos: 2,000 canciones, 1995-2025, con 10 atributos de audio, contexto y género.
- Partición temporal: entrenamos el modelo con 1,585 canciones de 1995-2019 y lo probamos una sola vez con 415 canciones de 2020-2025, porque se usará con canciones futuras.
- Todo lo que se aprende de los datos (escalas, categorías, coeficientes) lo incluimos dentro del pipeline y lo ajustamos solo con el entrenamiento.

2. Calidad de los datos

Revisión	Resultado	Decisión
Tamaño	2,000 filas × 13 columnas	—
Nulos	0 en todas las columnas	nada
Duplicados	0 filas	No se elimina nada
Valores extremos (regla IQR)	tempo 8, duración 7, volumen 5, acústica 1	Se conservan
Redundancia entre entradas	Ningún par con $\|r\| \geq 0.5$	No se elimina ninguna variable

Revisión	Resultado	Decisión
Géneros	pop 616, urbano 511, rock 333, electrónica 289, indie 251	Se codifican como indicadoras

Hicimos la exploración solo con el periodo de entrenamiento, para no mirar la prueba antes de tiempo. En las correlaciones notamos que reproducciones_sem1 (0.99) y es_hit (0.67) casi determinan la popularidad, así que revisamos si esas columnas estaban disponibles al momento de decidir.

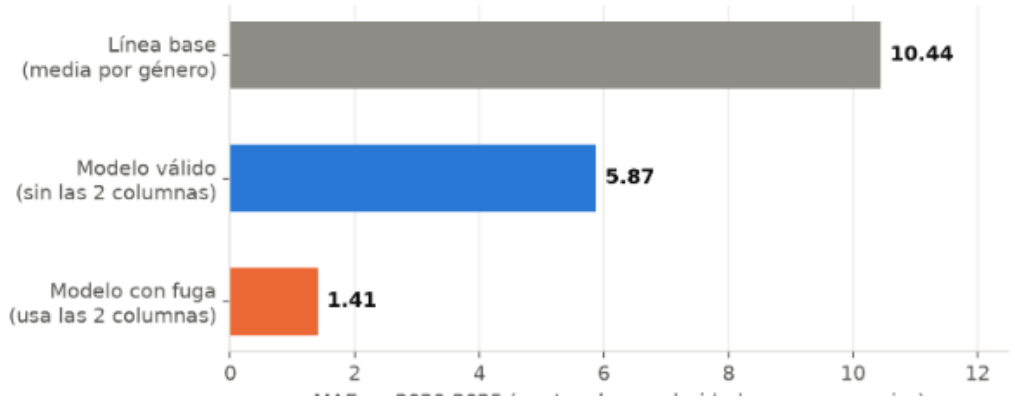


3. Control de fuga

Para cada columna nos preguntamos si existía en el momento de decidir. Hallamos que dos no existían.

Columna	¿Existe antes de lanzar?	Decisión
bailabilidad, energía, valencia, acústica, tempo, volumen	Sí: atributos de audio	Entra
año, colaboración, duración, género	Sí: se conocen al planear el lanzamiento	Entra
reproducciones_sem1	No: ocurre una semana después	Fuera (posterior al evento)
es_hit	No: se calcula con la popularidad	Fuera

Comparamos el mismo modelo lineal y la misma partición cambiando una sola cosa: incluir o no esas dos columnas. Con ellas el MAE baja a 1.41 (R^2 0.98); sin ellas es 5.87. Concluimos que el primer resultado no es válido

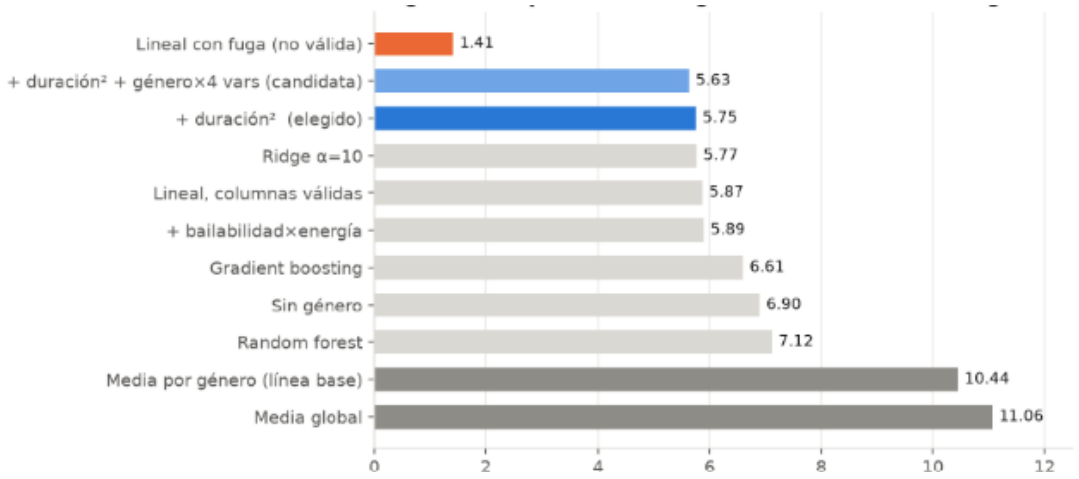


NOTA: Efecto de la fuga sobre el error en 2020-2025. Popularidad, en esta imagen menos es mejor

4. Modelos y registro comparativo

Medimos todas las corridas, incluidas las descartadas, sobre las mismas 415 canciones de 2020-2025 y las anotamos en registro_semana9.csv. Para elegir sin usar la prueba, hicimos la selección con validación interna de ventana creciente dentro del entrenamiento

la prueba solo informó el resultado final.



NOTA: MAE en la prueba de cada corrida. Azul: modelo elegido; azul claro: candidata propia; naranja: no válida por fuga.

Corrida	MAE prueba	MAE interno	Decisión
Media por género	10.44	—	Línea base
Lineal, columnas válidas	5.87	6.26	Referencia
Sin género	6.90	7.03	Descartada: el género aporta
+ bailabilidad×energía	5.89	6.28	Descartada: no mejora
+ duración²	5.75	6.06	Elegida (menor error interno)
+ duración² + género×4 variables	5.63	6.17	Candidata propia: no se elige con la prueba
Ridge α=10	5.77	6.07	Descartada: no mejora
Gradient boosting	6.61	6.87	Descartada: subestima la tendencia (sesgo 2.23)
Random forest (prof. 8)	7.12	7.40	Descartada: complejo

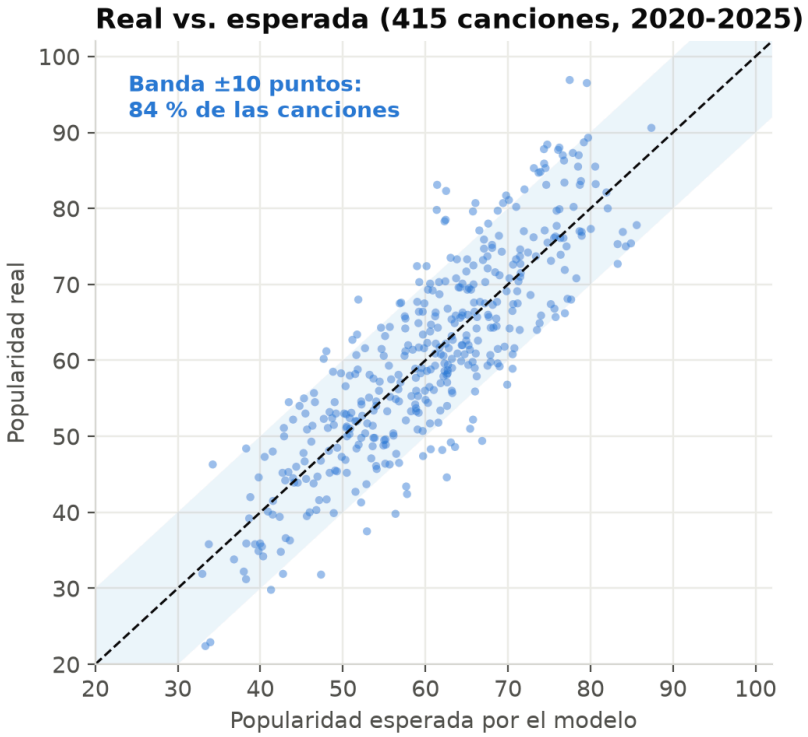
- Elegimos la regresión lineal con término de duración² (MAE interno 6.06; por pliegue 6.51, 5.99, 5.84 y 5.90).
- La partición aleatoria 80/20 da 5.83, casi igual al 5.75 de la temporal en este archivo; aun así usamos la temporal porque imita el uso real.

5. Métricas y conclusión de negocio

	MAE	RMSE	R^2	Sesgo
Línea base (media por género)	10.44	13.16	0.05	+2.92
Modelo elegido	5.75	7.15	0.72	+0.26

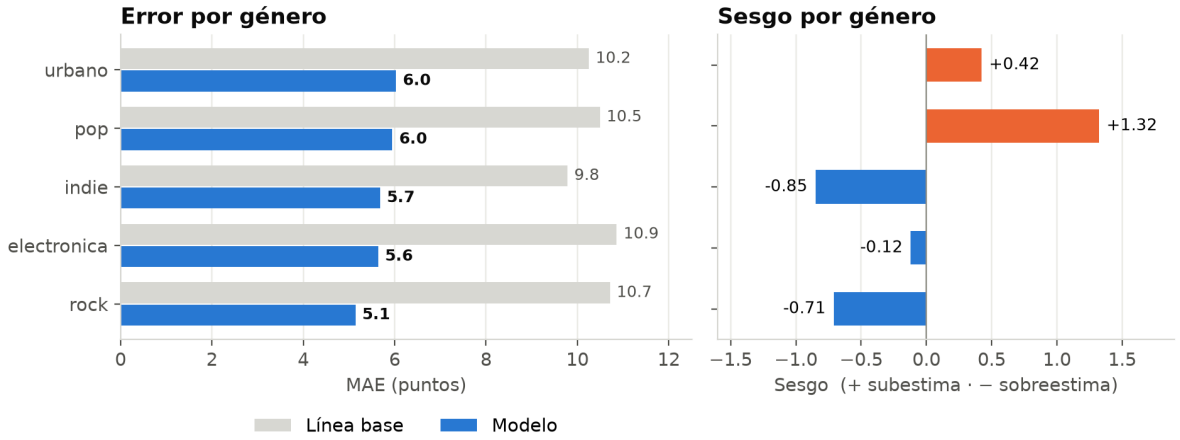
Hallamos que el error típico baja de 10.4 a 5.8 puntos (45 % menos). El RMSE (7.15) no está muy por encima del MAE, por lo que no hay errores extremos

66 de 415 canciones se alejan más de 10 puntos. El sesgo positivo pequeño indica que el modelo subestima levemente.

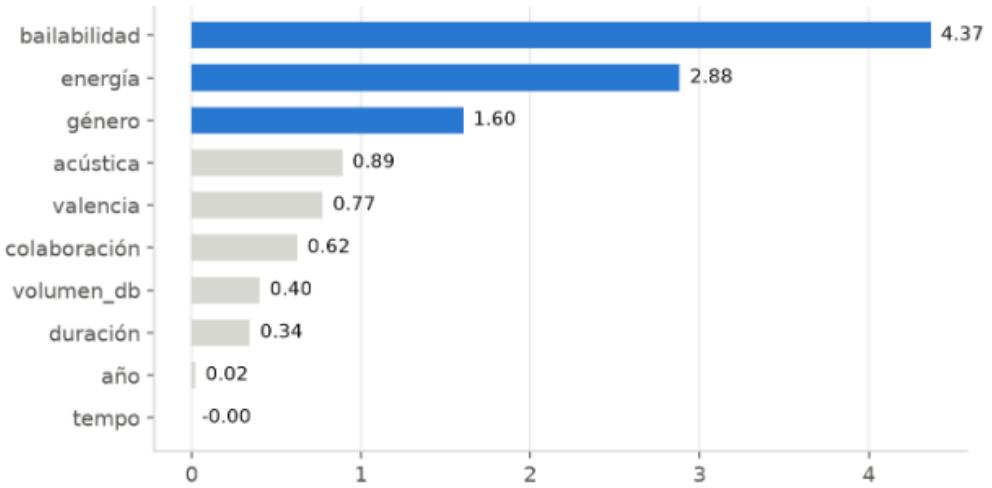


NOTA: Popularidad real frente a la esperada. La línea punteada es el acierto perfecto.

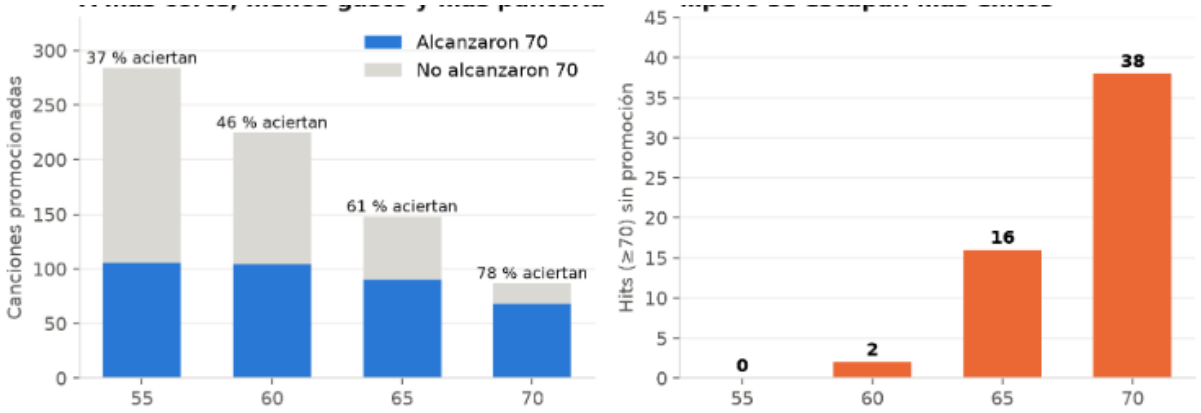
Al revisar por género, notamos que el modelo mejora a la línea base en todos los segmentos. El mayor error es el de urbano (MAE 6.03), el mayor sesgo es el de pop (+1.32: subestima) y el mejor desempeño es el de rock (5.14).



Calculamos la importancia por permutación es decir, cuánto empeora el MAE al barajar una variable, y hallamos que bailabilidad (4.37), energía (2.88) y género (1.60) dominan, mientras que tempo y año casi no aportan.



Consideramos que el corte de promoción debe fijarlo quien responde por el presupuesto y no la estadística. De las 415 canciones de 2020-2025, 106 alcanzaron 70 puntos.



Con corte 65 se promocionan 148 de 415 canciones; 90 de ellas (61 %) alcanzaron 70 y 16 hits quedaron sin promoción. Notamos que subir el corte reduce el presupuesto y mejora la proporción de aciertos, pero deja escapar más éxitos

Enlaces

Servicio en Render: https://popularidad-canciones-grupo1.onrender.com

Repositorio del servicio: https://github.com/CamilaAg-05/demo-reg-clas-canciones